

Engañé al gate de IA de tu pipeline: la firma seguía siendo válida y aun así no entró

Jean Paul López – Senior Consultant, Red Hat · Lima, Perú
Propuesta para **Black Alpaca 2026** · sesión de 50 min · español · nivel intermedio-avanzado

Laboratorio completo, reproducible y público
github.com/jeanlopez-talks/black-alpaca-peru-redteam-agentes-kubernetes-2026

1 · La tesis

Tu pipeline ya tiene agentes de IA revisando PRs y decidiendo gates. Cada uno es una **identidad nueva** con acceso a código, credenciales y producción.

Un control que lee texto escrito por el atacante no es un control de seguridad, por bueno que sea el modelo que hay detrás. Lo que aguanta es la plataforma.

La charla lo ataca en vivo sobre un laboratorio propio y enseña qué control sí frena a un agente que ya tiene credenciales.

2 · El laboratorio

Pipeline DevSecOps completo sobre un clúster **k3s propio**. Todo GitOps y reproducible. Sin nube de terceros y sin servicio externo de IA: el modelo corre dentro del clúster.

Pieza	Qué es
Pipeline	Tekton, 11 etapas: clone → pruebas → SAST → build → SBOM → escaneo → firma → procedencia → gate → verificación → despliegue
Supply chain	Registro OCI interno; firma y verificación por digest con cosign; SBOM con Syft; escaneo con Trivy
Admisión	Kyverno: exige firma válida y aprobación humana y que el cambio venga de Argo CD
Agentes	Cuatro, comunicados por A2A: atacante, revisor, remediación y aprobación
Modelo	Qwen3-8B servido con vLLM dentro del clúster : sin salida a internet y sin API key
Portal	Backstage: donde la persona ve lo que proponen los agentes y lo confirma

3 · Arquitectura

DE QUÉ DEPENDE · servicios del clúster

ninguno sale a internet

Almacén de imágenes
donde vive la imagen, su firma y su certificado

El modelo de IA
corre dentro del clúster, sin salir a internet

Puerta al catálogo
por aquí los agentes leen las políticas de seguridad

El control de admisión
decide qué puede entrar al clúster

EL PIPELINE · aquí corre el código del PR

aquí se ejecuta código que no controlas: sin credenciales del clúster

EL PIPELINE, PASO A PASO · DE IZQUIERDA A DERECHA

EMPIEZA AQUÍ
Se abre un PR
Código que no controlas.
→ dispara el PipelineRun

0 git-clone
trae el código del PR
EL ORIGEN POR CONSTRUIR

1 test
pasa las pruebas
CALIDAD POR CONSTRUIR

2 sast
busca fallos y secretos
SOLO AVISA

3 build
crea la imagen
IMAGEN REAL

4 sbom
lista qué lleva dentro
INVENTARIO

5 trivy-scan
busca vulnerabilidades
INFORMATIVO

5b remediation
la IA propone arreglos
INFORMATIVO

6 sign
sella la imagen
FIRMA REAL

7 attest
certifica su origen
CERTIFICADO POR CONSTRUIR

Agente ROJO · atacante
actúa en: gate-blue
Manda el PR al revisor. Sin credenciales ni acceso a internet.

8 gate-blue
el revisor decide
EL CORAZÓN

9 verify
comprueba el sello
SELLO VÁLIDO

when: decision==APPROVE && verify==OK

10 deploy-gitops
intenta desplegar
RECHAZADO

Agente AZUL · revisor
actúa en: gate-blue
Decide si el PR se aprueba o se bloquea. Es el objetivo del ataque.

QUÉ AGENTE ACTÚA EN CADA ETAPA

estos sí tienen credenciales — y aun así solo proponen, nunca aplican

Backstage · el portal
aquí entra la persona
Lee lo que proponen los agentes y confirma, o no, cada arreglo.

Agente de remediación
actúa en: remediation
Estudia las vulnerabilidades y propone cómo arreglarlas.

Agente de aprobación
observa todas las etapas
¿El revisor acordó o lo engañaron? Da una segunda opinión.

QUIÉN LO GOBIERNA · y quién decide qué entra

solo entra lo que está escrito en Git y aprueba una persona

Argo CD
mantiene el clúster igual a lo que dice Git

el pipeline
los agentes con IA

una ejecución por acto
la aplicación objetivo

las reglas de admisión

El único camino válido: una persona aprueba el cambio en Git, y Argo CD lo aplica. El agente puede falsificar una aprobación, pero no puede hacerse pasar por Argo CD.

4 · Los cuatro actos y su resultado

Acto	Qué hace el atacante	Resultado medido
1	PR malicioso evidente	El revisor lo bloquea . El control funciona cuando el ataque es obvio
2	Inyección indirecta en una dependencia	El revisor es engañado y aprueba
3	Instrucción escondida en el diff	Gana el gate , y la firma de la imagen verifica correctamente : el ataque toca la configuración, no la imagen
4	El mismo ataque contra el revisor endurecido	Bloqueado

El desenlace del acto 3 es el centro de la charla. El revisor aprobó, la firma es válida y el agente **tiene credencial real**. Y aun así el despliegue no entra: la admisión lo rechaza dos veces – primero porque falta la aprobación de una persona; después, cuando el agente se falsifica a sí mismo esa aprobación, porque el cambio no viene de Git.

5 · El hallazgo incómodo

Probé el revisor con el **modelo real** en lugar del motor de reglas:

Con Qwen3-8B local, el revisor **bloqueó las 5 ejecuciones**: ve el comando peligroso escondido tras la nota.

El engaño del acto 3 **solo ocurre con el motor de reglas**, donde obedecer la nota del PR está programado a propósito para que la demo sea reproducible. Lo presento tal cual porque es mejor material que la promesa original:

Un modelo mejor sube el listón. No lo convierte en un control. El atacante itera el encuadre; la admisión no negocia.

6 · Los agentes que sí aportan

El patrón que propongo para usar un modelo dentro de un pipeline sin confiar en él:

El modelo decide · el esquema acota · el código verifica

1. El **código** calcula hechos comprobables desde el grafo de dependencias: qué librerías carga de verdad la aplicación, con qué usuario arranca y qué comando ejecuta.
2. El **modelo** razona solo sobre esos hechos, con un formato de respuesta cerrado que el servidor de inferencia impone token a token.
3. El **código** verifica la respuesta y corrige al modelo si se inventó un paquete, una vulnerabilidad o una acción imposible. Cada corrección queda registrada y se muestra.
4. El **parche lo escribe el código**, nunca el modelo.

Resultado medido: la imagen baja de **37 a 13 vulnerabilidades graves**, con la aplicación funcionando – configuración válida y respuesta HTTP 200 – verificado reescaneando.

Y la frontera que importa: el agente **propone**, una persona **confirma** en Backstage y el cambio se escribe en Git para que lo aplique Argo CD. **El agente nunca toca el clúster.**

7 · Esquema de la sesión (50 min)

Min	Bloque
0-5	Los agentes ya están en tu pipeline: cada uno es una identidad con acceso a producción
5-12	El escenario: el pipeline de 11 etapas y los agentes que actúan en él
12-18	Acto 1 – el revisor bloquea el ataque obvio
18-26	Actos 2 y 3 – la instrucción escondida gana el gate, y la firma verifica igual
26-32	El hallazgo: con el modelo real, 5 de 5 bloqueados. Un modelo mejor no es un control
32-40	Lo que sí frena: la admisión rechaza al agente dos veces
40-47	Los agentes que aportan: 37 → 13 vulnerabilidades, y la persona confirma
47-50	Checklist para gobernar los agentes de tu pipeline. Preguntas

8 · Qué se lleva quien asiste

- Cómo se envenena un gate que lee texto escrito por el atacante.
- Por qué firmar y escanear son **necesarios y no suficientes**: la cadena de supply chain puede estar intacta mientras el ataque sigue vivo.
- Qué control sí frena a un agente que ya tiene credenciales.
- Un laboratorio **reproducible en GitOps** para probarlo en su propia infraestructura.

9 · Honestidad sobre el alcance

- Los resultados de este laboratorio son **propios**, medidos en mi clúster.
- La metodología de aislamiento parte del estudio de **Roy Belio (Red Hat)**, citado como fuente primaria; sus números no se presentan como míos.
- El ataque de los 3 000 millones de tokens (mayo 2026) se narra como **caso de estudio citado**, nunca replicado.
- La demo corre en vivo, con **grabación de respaldo** por si falla la red o la GPU.

Todo el material de esta propuesta es público
github.com/jeanlopez-talks/black-alpaca-peru-redteam-agentes-kubernetes-2026
Manifiestos GitOps del pipeline y las políticas · código de los cuatro agentes · diagrama interactivo · diapositivas · evidencias de cada medición.